

# Validación de rodamientos

## Evaluación de ensayo de vibraciones

Series temporales

Carlos G. Massobrio

# Tabla de CONTENIDOS

01

Motivación

02

Ensayo y Objetivo

03

Modelado Clásico

04

LSTM

05

Comentarios Fin.

# 01 - Motivación: Diseño mecánico



**Cambio en resistencia de materiales**

**Dos elementos importantes:**

- Frecuencia natural del sistema.
- Resistencia a la fatiga

**Las cargas incrementan su intensidad frente a excitaciones dinámicas**

**La tarea obtiene información:**

- Ensayos, en general destructivos.
- Tablas, gráficos de bibliografía

Resulta como práctica sobredimensionar parámetros para estar en “zona segura”



# 01 - Motivación: Mantenimiento Predictivo <<<<<

**Hoy**

Modelo basado en reglas

- Inspecciones regulares
- Control a equipamiento específico.
- Acceso a datos en tiempo real, pero no implica análisis.

**No siempre se pueden prevenir fallas**

>>>>> **Lo que se viene**

**AI + IoT**

ENSAYO  
HOY

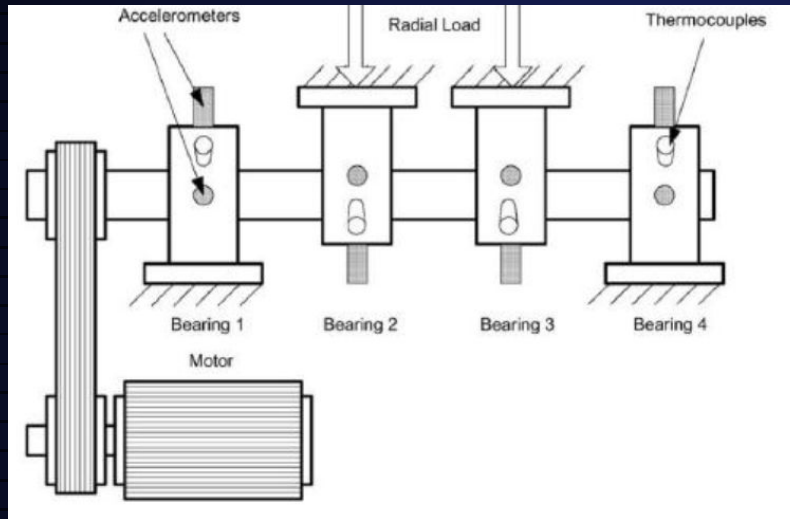
Datos p/  
Modelado AI

Parámetros p/  
Diseño mecánico

- Modelos predictivos p/detección de anomalías.
- “Vendors” ofrecen servicios cloud para desplegar modelos de series de tiempo en IoT industrial.
- Equipos embebidos con capacidad para emplear modelos pre-entrenados de ML



## 02 - Ensayo y Objetivos



### Ensayo destructivo a partir de datos de Nasa Bearing Dataset

- Eje montado sobre cuatro rodamientos.
- Los rodamientos N°2 y N°3 tienen cargas estáticas.
- Velocidad de giro: 2000RPM.
- Frecuencia de muestreo: 20KHz.
- Se consideran los últimos 3 minutos.
- #Datos: 3686400.

### TEST DE FALLA ROD. N°1

#### OBJETIVO de la PRESENTACIÓN

Presentar los resultados y gráficos más relevantes

Intentar responder: ¿Es estrictamente un problema de series de tiempo?



## 02 - Preparación de Datasets




Volumen grande de datos

Trabajo previo de compilación de  
archivos tipo ".39"


Selección de 4 muestras a modo de experimentos: 0.15s/3000 registros

Comportamiento de la serie en diferentes puntos









No perder datos relevantes (sino se requiere filtrado de ruido)







# 03 - Modelado Clásico: Autocorrelaciones <<<<<



## Observaciones


- Señales con predominantes componentes de ruido.
- La diferenciación a un paso no mejoró las curvas.
- Los test Dickey-Fuller y KPSS dan en todo los casos "estacionario".






# 03 - Modelado Clásico: Mejores configuraciones

TS-100s: ARMA(2,3)




TS-130s: ARMA(3,4)




Excepto TS-176s,  
ajustan bien



TS-160s: ARMA(3,4)



TS-176s: ARMA(3,4)




¿Será el efecto del  
ruido NO filtrado?

# 04 - LSMT

MISMAS MUESTRAS

Pruebas de arquitectura  
Correspondencia espectral

## Implementación Tensorflow



Muestra

Ventana

Capas

Neuronas  
p/capa

TS-100

20

3 / tanh

128

TS-130

15

4 / tanh

64

TS-160

9

5 / tanh

64

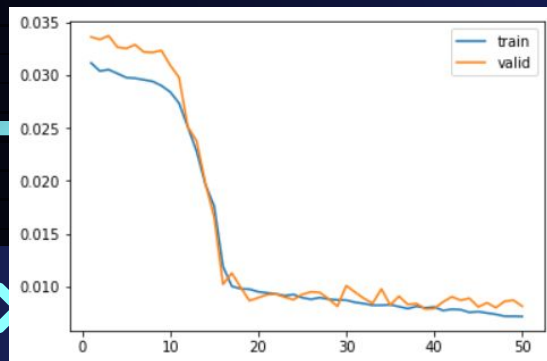
TS-176

9


6 / sigmoid

64


TS-130s



TS-160s



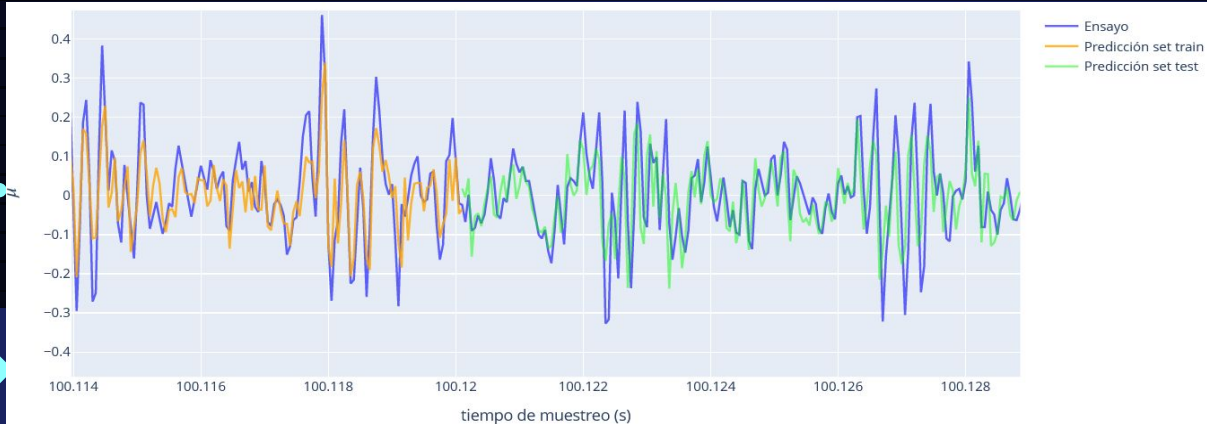

TS-176s



# 04 - LSMT

Caso testigo

TS-100




- No alcanza los máximos
- Por momentos se desfasa.

# 04 - LSMT: Periodograma

Caso testigo

TS-100



- No busco el futuro.
- Quiero detectar anomalías.

## Puntos destacados:

- Tanto en train como en test las frecuencias son las mismas apróx.
- Se reproduce en train y test la modulación (zona sombreada).

# 04 - LSMT: Periodograma

TS-130s




## Puntos destacados:

- Tanto en train como en test las frecuencias son las mismas apróx.
- Empieza a emerger la frecuencia contenida en la modulación. La representación en train y test sigue el patrón de la señal original.

# 04 - LSMT: Periodograma

TS-160s




## Puntos destacados:

- En train las frecuencias son las mismas apróx.
- En el caso de test, las primeras frecuencias relevantes, es más difícil ver que sean las mismas que la señal original.
- La modulación se ha perdido.



# 04 - LSMT: Periodograma

TS-176s



## Puntos destacados:

- Se hace evidente la presencia de mayor ruido.
- Solo algunas frecuencias en train y test coinciden con las correspondientes en la señal original.
- A no hay modulación alguna.

# 05 - Comentarios Finales


- Pruebas con dataset más grandes.
- Análisis completamente espectral.

- Preparación exhaustiva de datos.
- Mayor extracción/creación de *features*


Cambridge Series in Statistical and Probabilistic Mathematics

## Spectral Analysis for Univariate Time Series


Donald B. Percival  
Andrew T. Walden



- Entre 2021 y 2022 se han publicado muchos papers probando nuevas arquitecturas tipo LSTM.
- Optimización con tensores.
- Se busca evitar la realización de ensayos.
- Método efectivo de detección de anomalías.



### Traditional Data-driven methods



### Deep learning based method

